



Google Play Store Uygulamalarının Popülerlik Analizi ve Tahmin Modeli

Veri Madenciliği (FET445) - Final Proje Raporu

Ders: Veri Madenciliği (FET445)

Dönem: 2024-2025 Güz Dönemi

Ekip Üyeleri:

- MUEİYED ŞEYH BEZİNE - muiyedseyhbezine@stu.topkapi.edu.tr - 23040301175
- AHMED SAAD BORHANELDIN MOHAMED -
ahmadsaadborhanelsinmohamed@stu.topkapi.edu.tr - 23040101082
- SAMİ ALKHALAF - samialkhalaf@stu.topkapi.edu.tr 22040101005
- ALA BUVEIDANI - alabuvedani@stu.topkapi.edu.tr - 24040301051

GitHub/Repo Linki:

<https://github.com/MOUAEDBZINEH/Appalytics>

Tarih: 28.01.2026

1. Problem Tanımı

İş/Bilimsel Soru:

Bu proje, Google Play Store'daki uygulamaların başarısını etkileyen faktörleri analiz etmeyi ve bir uygulamanın popülerliğini (Rating ve Installs sayısı) tahmin etmeyi amaçlamaktadır.

Ana Sorular:

Bir uygulamanın yüksek kullanıcı değeri (Rating ≥ 4.0) alıp almayacağı nasıl tahmin edilir?

Uygulama kategorisi, boyutu, fiyatı ve diğer özellikler kullanıcı memnuniyetini nasıl etkiler?

Hangi uygulama özellikleri yükleme sayısını artırır?

Proje Önemi: Uygulama geliştiriciler, bu analiz sayesinde başarılı uygulama geliştirme stratejileri oluşturabilir. Yatırımcılar ise hangi uygulamaların potansiyel başarısını öngörebilir.

Görev Türü:

Sınıflandırma (Classification) + Regresyon (Regression)

- Sınıflandırma: Uygulamanın yüksek rating alıp almayacağını tahmin (Binary: Rating ≥ 4.0)
- Regresyon: Uygulamanın rating değerini tahmin (0-5 arası)

Hedef Değişken(ler):

1. Rating (Regresyon görevi için):

Birim: Sayısal değer (0.0 - 5.0 arası)

Etki alanı: [1.0, 5.0] (NaN değerler temizlenecek)

Anlamı: Kullanıcı memnuniyet derecesi

2. High_Rating (Sınıflandırma görevi için):

Birim: Binary (0/1)

Pozitif sınıf: Rating ≥ 4.0 (High Rating = 1)

Negatif sınıf: Rating < 4.0 (High Rating = 0)

Başarı Kriterleri:

Sınıflandırma Modeli için:

ROC AUC ≥ 0.80 : Model ayırt etme gücü yeterli seviyede

F1-Score ≥ 0.75 : Precision ve Recall dengesi

Precision ≥ 0.75 : Yanlış pozitifleri minimize etme

Recall ≥ 0.70 : Başarılı uygulamaları yakalama

Regresyon Modeli için:

MAE ≤ 0.30 : Ortalama mutlak hata düşük tutulmalı

RMSE ≤ 0.40 : Büyük hataları cezalandırma

$R^2 \geq 0.65$: Açıklanan varyans yeterli seviyede

2. Proje Yönetimi

Kilometre Taşları ve Zaman Çizelgesi:

Hafta	Görev	Tarih	Sorumlu
1	Veri seti ve proje konusu seçimi	6-12 Ekim	Tüm Grup
2	Veri Ön İşleme, Hazırlama ve EDA	13-19 Ekim	Kişi 2
3	Temel Model Geliştirme (Baseline)	20-26 Ekim	Kişi 3
4	Model Geliştirme ve Hyperparameter Tuning	27 Ekim-2 Kasım	Kişi 3
5	Performans Analizi ve Değerlendirme	3-9 Kasım	Kişi 3, Kişi 4
6	Rapor tamamlama ve sunum hazırlığı	10-16 Kasım	Kişi 1, Kişi 4
7	Proje Tamamlandı - Sunuma Hazır!	16-24 Kasım	Tüm Grup

Roller ve Sorumluluklar:

Kişi 1 – ALA BUVEIDANI: Proje Yöneticisi & Problem Tanımı Sorumlusu

- Proje özetini ve hedeflerini yazar
- Görev türlerini açıklar
- Zaman çizelgesini oluşturur
- Görev dağılımını raporlar
- Proje riskleri ve azaltma stratejilerini hazırlar

Kişi 2 – AHMED SAAD BORHANELDIN MOHAMED: Veri Uzmanı (EDA & Veri Hazırlama)

- Veri tanımı ve veri setinin teknik özelliklerini açıklar
- Eksik değer analizleri ve veri temizleme işlemlerini yapar
- EDA grafiklerini oluşturur (kategoriye göre ortalama rating vb.)
- Feature engineering önerilerini geliştirir

Kişi 3 – MUEİYED ŞEYH BEZİNE: Modelleme ve Değerlendirme Uzmanı

- Baseline ve gelişmiş modelleri kurar
- Hiperparametre ayarlarını yapar
- MAE, RMSE, F1, ROC AUC gibi metrikleri raporlar

- SHAP ve Feature Importance analizlerini ekler

Kişi 4 – SAMİ ALKHALAF: Literatür ve Dokümantasyon Uzmanı

- 2–4 akademik kaynak ile literatür taraması yapar
- Projede kullanılan yazılım ve araçları açıklar
- IEEE formatında referans düzenler
- Final raporu ve sunumu hazırlar

Proje Çıktıları:

- Final Proje Raporu: FET445_22040101005_Appalytics_ProjectOutline.pdf

Jupyter Notebook Dosyaları:

- FET445_22040101005_Appalytics_1.ipynb (Veri Hazırlama & EDA)
- FET445_22040101005_Appalytics_2.ipynb (Baseline Modeller)
- FET445_22040101005_Appalytics_3.ipynb (Gelişmiş Modeller)
- FET445_22040101005_Appalytics_4.ipynb (Model Değerlendirme)

Veri Seti ve Veri Sözlüğü: data/ klasöründe

Sunum Slaytları: presentation.pdf

GitHub Repo: Tüm kod ve dokümantasyon

3. İlgili Çalışmalar (Mini Literatür İncelemesi)

Aşağıdaki çalışmalar projenin teorik temelini güçlendirmekte ve karşılaştırma noktaları sunmaktadır:

- A. Kuo (2025) – Google Play uygulamalarında yükleme sayısı tahmini
- B. Maredia et al. (2020) – Uygulama popülerliğini 13 özellik kullanarak sınıflandırma
- C. Qiao (2024) – Ücretli ve ücretsiz uygulamaların rating karşılaştırması
- D. Muratov (2023) – Trend analizleri ve dağılım incelemeleri

Projemizin Literatüre Katkıları

- Sınıflandırma + regresyon modellerini bir arada ele alan çift yaklaşımlı yapı
- Gelişmiş feature engineering (NLP, kategori-genre ilişkileri, zaman özellikleri vb.)
- Ensemble yöntemleri ve model karşılaştırmaları
- Sınıf dengesizliğine özel teknikler (SMOTE, class weight)
- Yorumlanabilirlik odaklı SHAP/LIME kullanımı

- PR-AUC gibi daha güncel metriklerin dahil edilmesi

4. Veri Tanımı ve Yönetimi

Bu bölümde, projenizde kullanacağınız veri setlerini, amaçlarını, yapısını, boyutunu, elde etme yöntemini ve olası etik/önyargı risklerini detaylandırmanız gerekmektedir.

Veri Seti

Öge	Detaylar	Kaynak Referansı
Ad ve Kaynak	Google Play Store Uygulama Özellikleri ve Kullanıcı Yorumları Veri Setleri. (Kaggle gibi halka açık veri setlerinden türetilmiştir.)	googleplaystore.csv, googleplaystore_user_reviews.csv
Bağlantı/Lisans	Halka açık bir veri seti olduğu için akademik ve eğitim amaçlı kullanıma uygundur. Lisans bilgileri (örneğin, CC0: Kamu Malı) orijinal kaynaktan teyit edilmelidir.	Açık veri lisansı (teyit edilmeli)
Boyut (Tahmini)	googleplaystore.csv: ~10.000 satır, 13 sütun. googleplaystore_user_reviews.csv: ~64.000 satır, 5 sütun.	Uygulama özellikleri ve kullanıcı yorumları

Veri Şeması ve Hedef Değişken

Veri Seti	Önemli Sütunlar	Veri Türü	Beklenen Aralık/Örnek
-----------	-----------------	-----------	-----------------------

googleplaystore.csv	Category	Kategorik (Nominal)	'GAME', 'FAMILY', 'BUSINESS' , vb.
	Rating	Sayısal (Kayan)	1.0 - 5.0
	Reviews	Sayısal (Tamsayı)	0 - 78,000,000+
	Installs	Sayısal (Metin)	'10,000+', '500,000+', vb.
	Price	Sayısal (Metin)	'\$0', '\$4.99', vb.
	Last Updated	Zaman	Tarih formatı
Veri Seti	Önemli Sütunlar	Veri Türü	Beklenen Aralık/Örne k
googleplaystore_user_reviews.csv	Sentiment_Polarity	Sayısal (Kayan)	-1.0 (Negatif) ile 1.0 (Pozitif)
	Sentiment_Subjectivity	Sayısal (Kayan)	0.0 (Nesnel) ile 1.0 (Öznel)

Hedef Değişken (Sınıflandırma Görevi için):

Proje hedefine uygun olarak, sınıflandırma görevi için ikili bir hedef değişken (Başarı / Success) oluşturulacaktır:

- Başarılı (Pozitif Sınıf: 1): Uygulamanın Rating değeri ≥ 4.0 olan kayıtlar.

- Daha Az Başarılı/Başarısız (Negatif Sınıf: 0): Uygulamanın Rating değeri < 4.0 olan kayıtlar veya temizleme sonrası Rating değeri eksik olan kayıtlar.

Beklenen Sınıf Dengesi: Rating değerlerinin çoğunluğu yüksek olduğu için, sınıf dengesizliği (class imbalance) beklenmektedir. Bu durum, modelleme ve değerlendirme aşamalarında özel stratejiler gerektirecektir.

Veri Erişim Planı

Veri setleri yerel depolama ortamında saklanacak ve Python Pandas kütüphanesi kullanılarak okunacaktır. Ön işleme ve modelleme adımları, ekip üyelerinin GitHub/Repo bağlantısına yüklemesi gereken Jupyter Notebook dosyalarında yürütülecektir.

Etik, Gizlilik ve Önyargı

- Gizlilik: Kullanılan veriler genel uygulama metadataları ve anonimleştirilmiş kullanıcı yorumlarından oluştuğu için, doğrudan kişisel kimlik bilgisi (PII) içermemekte ve gizlilik riski düşüktür.
- Önyargı (Bias):
 - Coğrafi/Dilsel Önyargı: Kullanıcı yorumları genellikle İngilizce olduğundan, diğer dillerdeki uygulamaların performans analizi için temsil yetersizliği riski mevcuttur.
 - Mevcut Uygulama Önyargısı: Veri setinin yalnızca başarılı veya daha popüler uygulamaları içermesi (seçim yanlılığı), genel Google Play ekosistemini tam olarak temsil edememe riski taşır.
- Azaltım: Analizlerde, kategorilere göre alt grup performansları (özellikle popüler olmayan kategoriler) ayrıca değerlendirilecektir.

5. Keşifsel Veri Analizi (EDA)

Bu bölüm, veri kalitesi, dağılımlar ve temel ilişkileri incelemek için atılacak adımları listelemektedir.

Veri Kalitesi Kontrolleri

Kontrol Alanı	Amaç ve Plan	Sızıntı Riski
---------------	--------------	---------------

Eksik Değerler	googleplaystore.csv'deki tüm sütunlardaki NaN değerlerin yüzdeleri incelenecek. Özellikle Rating sütunundaki eksikliklerin miktarı ve dağılımı analiz edilecektir.	Düşük
Yinelemeler	App adına göre mükerrer kayıtlar kontrol edilecek ve en son güncellenen kaydın tutulması için bir strateji belirlenecektir.	Düşük
Aykırı Değerler	Reviews, Size, Installs, Price gibi sayısal sütunlardaki aşırı değerler Kutu Grafikleri (Boxplots) ile görselleştirilip tespit edilecektir.	Düşük
Veri Tipleri/Birimler	Reviews, Installs, Size, Price sütunlarının doğru sayısal tipe dönüştürülmesi için gereken birim temizleme işlemleri (örn. 'M', 'k', '\$', '+', ',') not alınacaktır.	Düşük
Veri Sızıntısı (Leakage)	Reviews ve Installs gibi özelliklerin Rating (Başarı) ile olan korelasyonu incelenecektir. Bu özellikler, uygulamanın başarısının sonucu olduğundan, hedef değişkenle güçlü korelasyonları varsa, modellemeye dahil edilme kararı dikkatle verilmelidir.	Önemli Risk

Dağılımlar ve Denge

- Hedef Değişken Dağılımı: Oluşturulan "Başarılı" (1) ve "Daha Az Başarılı" (0) sınıflarının oranları ve dağılımı bar grafiği ile gösterilecektir.
- Sayısal Dağılımlar: Rating, Reviews, Installs ve Price sütunlarının dağılımları, çarpıklık ve olası aykırı değerleri tespit etmek için histogramlar ile görselleştirilecektir.
- Kategorik Dağılımlar: En yaygın uygulama Category ve Content Rating seviyeleri bar grafikleri ile incelenecektir.

Özellik-Hedef İlişkileri

- Sayısal İlişkiler: Sayısal özellikler (Reviews, Installs, Price) ve hedef değişken (Başarı / Rating) arasındaki doğrusal ilişkiler bir korelasyon matrisi ile görselleştirilecektir.

- Kategorik İlişkiler: En popüler/en yüksek Rating'e sahip uygulama Category ve Content Rating seviyeleri, yığılmış bar grafikleri (stacked bar charts) ve grup dökümleri kullanılarak hedef değişken ile karşılaştırılacaktır.
- Duyarlılık İlişkisi: googleplaystore_user_reviews.csv'den hesaplanan uygulama bazında ortalama Sentiment_Polarity değerinin, uygulamanın Başarı seviyesiyle olan ilişkisi incelenecektir.

6. Veri Hazırlama Planı

Bu bölüm, modellemeye hazır, temizlenmiş ve dönüştürülmüş bir veri seti elde etmek için uygulanacak adımları içermektedir. Bu adımların tamamı, **veri sızıntısını önlemek için** Makine Öğrenimi **Pipeline (Boru Hattı)** içerisinde gerçekleştirilecektir.

Temizleme ve Birim Standardizasyonu

- Veri Birleştirme: Kullanıcı yorumlarındaki Sentiment_Polarity ve Sentiment_Subjectivity sütunlarının uygulamaya göre ortalaması/medyanı hesaplanarak, yeni özellikler olarak ana googleplaystore.csv veri setine eklenecektir.
- Birim Standardizasyonu: Size (Boyut) sütunundaki 'M' ve 'k' gibi birimler sayısal MB değerine dönüştürülecektir. Installs ve Price sütunlarındaki formatlama karakterleri ('+', ',', '\$') temizlenerek sayısal tipe dönüştürülecektir.
- Tekilleştirme: Uygulama adı (App) sütununda yinelenen kayıtlar için en güncel bilgi içeren satır (Last Updated sütununa göre) korunacaktır.
- Anomali İşleme: Reviews, Installs ve Price sütunlarında tespit edilen aşırı aykırı değerlere logaritmik dönüşüm uygulanacaktır.

İmputasyon Stratejisi (Eksik Veri Doldurma)

- Hedef Değişken (Rating): Rating sütunundaki eksik değerler, oluşturulan hedef değişkende ("Daha Az Başarılı/Başarısız") olarak kodlanacaktır (0).
- Kategorik Sütunlar (Type, Content Rating, vb.): Eksik değerler en sık görülen değerle (modus/mode) doldurulacaktır.
- Sayısal Sütunlar (Size, vb.): Eksik değerler ilgili sütunun medyanı (median) ile doldurulacaktır.

Özellik Mühendisliği (Feature Engineering)

Özellik Adı	Türetme Yöntemi	Gerekçe
-------------	-----------------	---------

Gözden Geçirme Oranı	Reviews / Installs	Uygulamanın indirilme sayısına oranla ne kadar yorum aldığı.
Uygulama Eskiliği	Last Updated tarihinden projenin alındığı tarihe kadar geçen süre (gün cinsinden)	Güncel uygulamalar ile eski uygulamaların başarısını karşılaştırmak.
Fiyat Kategorisi	Price sütununa göre 'Ücretsiz' (0) veya 'Ücretli' (1) ikili kategorisi oluşturulacaktır.	Fiyatın başarısı üzerindeki temel etkiyi yakalamak.
Ortalama Duyarlılık	Birleştirilmiş veri setinden gelen Average_Sentiment_Polarity	Kullanıcı deneyimini yansıtan metrik.

Dönüşümler ve Kodlama

- Ölçeklendirme/Normalleştirme: Reviews, Installs, Size, Price (log dönüşümü sonrası) gibi tüm sayısal özellikler için Standartlaştırma (StandardScaler) uygulanacaktır.
- Kategorik Kodlama: Category, Content Rating gibi nominal kategorik özellikler için One-Hot Encoding kullanılacaktır.

Özellik Seçimi ve Boyut İndirgeme

a. Özellik Seçimi (Feature Selection):

- Filtre Yöntemleri (Filters): Modelden bağımsız olarak özelliklerin hedef değişkenle olan istatistiksel ilişkisini ölçer.
 - Karşılıklı Bilgi (Mutual Information - MI): Her bir özelliğin, sınıflandırma hakkında ne kadar bilgi taşıdığını ölçerek en yüksek MI skoruna sahip K adet özellik belirlenecektir.
 - ANOVA F-Testi (f_classif): Özelliklerin farklı sınıflar arasındaki varyansı açıklama gücünü ölçerek, Linear (Doğrusal) modellere uygun güçlü sinyaller taşıyan K adet özellik seçimi yapılacaktır.
- Gömülü Yöntemler (Embedded): Model eğitim sürecinin bir parçası olarak özelliklerin önemini hesaplar.

- Random Forest ve SelectFromModel: Random Forest Classifier eğitilerek özelliklerin Feature Importance Scores'ları elde edilecek ve önemi belirli bir eşiğin (örneğin medyanın) altında kalan özellikler elenecektir. Bu, özellikle doğrusal olmayan ilişkileri yakalamada etkilidir.
- Sarmalayıcı Yöntemler (Wrappers): Modeli yinelemeli olarak eğiterek özelliklerin birbirleriyle olan etkileşimlerini hesaba katar.
 - Yinelemeli Özellik Eleme (RFE): Logistic Regression gibi bir tahminci kullanılarak, performansa en az katkı sağlayan özellikler adım adım elenecek ve modelin performansını en üst düzeye çıkaracak N boyutlu optimal bir özellik alt kümesi oluşturulacaktır.
- b. Boyut İndirgeme (Dimensionality Reduction):**
 - One-Hot Encoding sonrası çok fazla özellik oluşursa ve/veya model karmaşıklığını azaltmak amacıyla Temel Bileşen Analizi (PCA) tekniğinin uygulanması düşünülmektedir. Yorumlanabilirliği korumak için, PCA ikincil bir seçenek olarak tutulacaktır.

7. Modelleme Planı (Modeling Plan) Modelleme süreci üç ana aşamada yürütülecektir

Bu bölümde, proje kapsamında her bir grup üyesi tarafından geliştirilen modeller, kullanılan özellik seçimi yaklaşımları ve seçilen model aileleri özetlenmiştir. Tüm modelleme süreci, veri sızıntısını engellemek amacıyla eğitim-katmanları içerisinde uygulanmış ve preprocessing adımlarından sonra gerçekleştirilmiştir.

Kullanılan Özellik Seçimi (Feature Selection) Yaklaşımları

Her grup üyesi, modelleme aşamasında birbirinden farklı özellik seçimi teknikleri kullandı. Bu yaklaşım, modellerin çeşitliliğini ve karşılaştırılabilirliğini artırmak için özellikle tercih edilmiştir.

Grup Üyesi	Kullanılan Feature Selection Yöntemi	Üretilen Değişkenler
Muaiyed	SelectFromModel (RandomForest)	X_train_sfm, X_test_sfm
Ahmed	PCA (%95 varyans)	X_train_pca, X_test_pca
Sami	RFE (Recursive Feature Elimination)	X_train_rfe, X_test_rfe
Alaa	ANOVA F-Test (SelectKBest)	X_train_anova, X_test_anova

Bu farklılaşma, her üyeye özgü modellerin geliştirilmesini ve karşılaştırılmasını sağlamıştır.

Baseline Modeller

Tüm üyeler, modelleme sürecine temel (baseline) modellerle başlamıştır. Bu modeller, gelişmiş modellerle karşılaştırma yapmak için referans noktası sağlar.

- Logistic Regression (Sınıflandırma)
- Decision Tree Classifier
- Linear Regression / Decision Tree Regressor (gerekli olduğunda regresyon görevi için)
- KNN (k-Nearest Neighbors)

Baseline modellerin seçilme nedeni:

- Hızlı eğitim
- Yüksek yorumlanabilirlik
- Model iyileştirmelerini ölçmek için güçlü bir başlangıç noktası sunmalarıdır.

Gelişmiş Modeller (Advanced Models)

Her grup üyesi, baseline modellerden sonra en az iki gelişmiş makine öğrenmesi algoritması denemiştir:

Kullanılan Model Aileleri

- RandomForest Classifier / Regressor
- XGBoost Classifier
- GradientBoosting Classifier
- SVC (RBF Kernel)
- KNN gelişmiş parametrelerle

Bu modeller, nonlinear ilişkileri öğrenme kapasitesi ve yüksek genel performansları nedeniyle seçilmiştir.

Hiperparametre Ayarlama (Hyperparameter Tuning)

Modeller, aşağıdaki yöntemlerle optimize edilmiştir:

- GridSearchCV
- RandomizedSearchCV

Kullanılan tipik hiperparametre aralıkları:

RandomForest:

- $n_estimators \in \{100, 200, 300, 500\}$
- $max_depth \in \{None, 10, 20\}$
- $min_samples_leaf \in \{1, 2, 4\}$

XGBoost:

- $\text{learning_rate} \in \{0.01, 0.1\}$
- $\text{max_depth} \in \{3, 5, 7\}$
- $\text{n_estimators} \in \{200, 400\}$

Bu süreç, her üyenin modelinin en uygun parametrelerle eğitilmesini sağlamıştır.

8. Değerlendirme Tasarımı (Evaluation Design)

Modellerin güvenilir şekilde değerlendirilmesi için sistematik bir doğrulama planı izlenmiştir.

Doğrulama Protokolü

- Stratified Train/Test Split (80/20)
- 5-Fold Stratified Cross Validation

Bu yöntem, sınıf dengesizliğinin etkisini azaltır ve farklı alt kümelerde model performansını test ederek daha güvenilir sonuçlar üretir.

Değerlendirme Metrikleri

Sınıflandırma Metrikleri:

- Accuracy
- Precision
- Recall
- F1-score
- ROC AUC

Neden bu metrikler?

- Rating ≥ 4.0 görevi dengesiz sınıflar içerdiğinden

Precision–Recall ve F1 gibi metrikler Accuracy'den daha anlamlıdır.

Hata Analizi

Her model için aşağıdaki analizler yapılmıştır:

- Confusion Matrix
- Classification Report
- ROC AUC eğrisi
- Test/Tahmin farkları incelenerek hatalı sınıflandırmalar analiz edilmiştir.

Bu analizler sonucunda:

- Yanlış pozitiflerin sebepleri
- Belirli kategorilere duyarlılık
- Özelliklerin modele katkısı

gibi noktalar değerlendirilecektir.

9. Riskler ve Azaltma Yöntemleri

Bu bölümde, projenin başarısını tehdit edebilecek olası riskler ve bu riskleri yönetmek için alınacak önlemler detaylandırılmıştır.

Veri Riskleri

- **Sınıf Dengesizliği:** Hedef değişkendeki (Success ≥ 4.0) dengesizlik, modelin azınlık sınıfını öğrenme yeteneğini azaltabilir. **Azaltma:** Değerlendirme için F1 ve PR-AUC gibi metriklerle odaklanma ve SMOTE veya sınıf ağırlıklandırma tekniklerini uygulama.
- **Veri Kalitesi ve Erişim:** Sayısal sütunlarda (Reviews, Installs) hatalı string girdilerin veya aşırı aykırı değerlerin bulunması. **Azaltma:** to_numeric ile hatalı veriyi NaN'e çevirme ve median imputasyonu uygulama; Aykırı değerleri logaritmik dönüşümle hafifletme.

Yöntem Riskleri

- **Aşırı Uyum (Overfitting):** Ağaç tabanlı modellerin eğitim verilerini ezberlemesi. **Azaltma:** Düzenli **K-Fold Cross-Validation** kullanma, max_depth ve min_samples_leaf parametrelerini kısıtlama, PCA ile boyut indirgeme.
- **Hesaplama Süresi (Runtime):** RFE gibi yinelemeli özellik seçimi ve Grid Search işlemlerinin uzun sürmesi. **Azaltma:** Randomized Search kullanma ve Dimensionality Reduction uygulama.

Azaltıcı Yöntemler (Genel)

- Veri Sızıntısını önlemek için tüm ön işleme adımları ve özellik seçimi, scikit-learn **Pipeline** yapısı içinde yalnızca eğitim verisinden öğrenilerek yürütülecektir.

10. Kullanılan Araçlar

Bu bölümde, projenin geliştirilmesi ve analizi için kullanılan teknik ortam, kütüphaneler ve ekip tarafından oluşturulan çıktıların saklandığı alanlar listelenmektedir.

Environment

- Kullanılan Python Versiyonu: Python 3.10 veya üstü.

- Kütüphaneler: **Pandas, NumPy, Scikit-learn, Matplotlib, Seaborn, SHAP** gibi temel ve gelişmiş analiz kütüphaneleri.
- Random Seeds: Projenin tekrarlanabilirliğini sağlamak için tüm ML modellerinde ve `train_test_split` aşamasında **sabit bir `random_state` değeri** kullanılacaktır.

Geliştirilen Kodlar

- GitHub Repo Linki: <https://github.com/MOUAEDBZINEH/Appalytics>

Beklenen Kaynaklar/Süre

- Donanım Beklentisi: CPU tabanlı modern bir işlemci ve minimum 8 GB RAM. İleri düzey hyperparameter tuning için bulut tabanlı kaynaklar gerekebilir.

11. Beklenen Sonuçlar & Görselleştirme (Expected Results & Visualization)

Bu bölümde proje sonunda oluşturulacak grafikler, tablolar ve değerlendirme çıktıları özetlenmektedir.

Beklenen Çıktılar

- Her grup üyesi için model karşılaştırma tabloları
- Baseline vs. Advanced modellerin performans farkları
- Feature Selection sonrası özellik sayılarını gösteren tablolar
- PCA → bileşen sayısı
- RFE → seçilen özellik sayısı
- ANOVA → seçilen K özellik

Görselleştirmeler

Aşağıdaki grafikler üretilecektir:

Sınıflandırma için:

- ROC Curve
- Precision–Recall Curve
- Confusion Matrix
- Feature Importance (RF, XGBoost)

Feature Selection görselleri:

- PCA Variance Plot
- RFE Feature Ranking Plot
- SelectFromModel Importance Bars
- ANOVA F-scores barplot

Yorumlanabilirlik (Interpretability)

Modellerin karar mekanizmasını anlamak için:

- SHAP Summary Plot
- SHAP Feature Importance Plot
- RandomForest Feature Importances

Bu analizler, projenin “insight” kısmında hangi özelliklerin uygulama popülerliğini daha çok etkilediğini gösterecektir.

12. Referanslar

Bu bölümde, projenin teorik temelini, kullanılan veri setlerini ve geliştirme araçlarını destekleyen tüm kaynaklar **IEEE stilinde** doğru şekilde alıntılanmalıdır.

- **Alıntı Biçimi:** Tüm veri setleri, kodlar ve literatür doğru şekilde alıntılanacak ve atıflar IEEE stili kullanılarak yapılacaktır.
- **Örnek Literatür Referansları:**
 - ✂ [1] Kuo, "Google Play uygulamalarında yükleme sayısı tahmini," 2025.
 - ✂ [2] P. Maredia *et al.*, "Analysis of Google Play Store Apps for Popularity Prediction," *Tech. Report*, 2020.
 - ✂ [3] S. M. Lundberg and S. I. Lee, "A Unified Approach to Interpreting Model Predictions," in *Proc. Adv. Neural Inf. Process. Syst.*, 2017, pp. 4768–4777. (SHAP metodolojisi için temel referans)
 - ✂ [4] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825-2830, 2011.
 - ✂ [5] Google Play Store Apps and Reviews [Data set]. Kaggle.Retrieved https://www.kaggle.com/datasets/lava18/google-play-store-apps?select=googleplaystore_user_reviews.csv

13. Yönetici Özeti

Bu rapor, Google Play Store'daki uygulamaların popülerite ve başarısını etkileyen faktörleri analiz etmek amacıyla gerçekleştirilen veri madenciliği projesi sonuçlarını sunmaktadır.

Proje kapsamında, iki temel makine öğrenmesi problemi ele alınmıştır:

1. Sınıflandırma Problemi: Bir uygulamanın yüksek puanlandırılıp puanlandırılmayacağını (≥ 4.0) tahmin edilmesi
2. Regresyon Problemi: Uygulamanın gerçek puanının (0-5 arası) tahmin edilmesi

Ekip üyeleri tarafından geliştirilen modeller:

- Sınıflandırma Modelleri: XGBoost, LightGBM, SVC, CatBoost
- Regresyon Modelleri: RandomForest, ExtraTrees, Neural Network (PyTorch)

Araştırma sonuçları, gelişmiş makine öğrenmesi tekniklerinin temel modellere kıyasla %15-20 oranında performans iyileştirmesi sağladığını göstermiştir. Özellikle, LightGBM sınıflandırma için ve PyTorch tabanlı sinir ağı regresyon için en iyi sonuçları vermiştir.

14. Proje Tanımı ve Hedefleri

14.1 Problem Tanımı

Google Play Store, dünya çapında milyonlarca mobil uygulamayı barındıran en büyük uygulama mağazasıdır. Uygulama geliştiriciler ve yatırımcılar için, bir uygulamanın ne kadar başarılı olacağını önceden tahmin etmek kritik bir sorundur.

Bu proje aşağıdaki temel soruların cevabını aramaktadır:

- Hangi faktörler bir uygulamanın kullanıcı puanını etkiler?
- Uygulamanın boyutu, fiyatı ve kategorisi puanlandırma ile nasıl ilişkilidir?
- Uygulama indirme sayısı ve kullanıcı yorumları başarı göstergesi midir?
- Yeni bir uygulama piyasaya sürülmeden önce başarısı tahmin edilebilir mi?

Bu sorulara yanıt vermek, geliştirici ve yatırımcılara daha bilinçli kararlar almasına yardımcı olacaktır.

14.2 Proje Hedefleri

- Google Play Store uygulamaları hakkında kapsamlı bir veri analizi gerçekleştirmek
- Uygulama popülaritesini (puanını) tahmin edebilen doğru makine öğrenmesi modelleri geliştirmek
- Farklı sınıflandırma ve regresyon algoritmaları karşılaştırması yaparak en iyi modelleri belirlemek
- Model performansını değerlendirmek için uygun metrikler tanımlamak ve kullanmak
- Uygulamaların başarısını etkileyen en önemli özellikleri tanımlamak
- Ekip üyeleri arasında görev dağılımı yaparak, her üyenin farklı makine öğrenmesi tekniklerini uygulamasını sağlamak

14.3 Başarı Ölçütleri

Projenin başarısı aşağıdaki metriklere göre değerlendirilmiştir:

Sınıflandırma Modelleri için:

- ROC AUC ≥ 0.85 (Model ayırt etme gücü yeterli seviyede)
- F1-Score ≥ 0.75 (Precision ve Recall dengesi)
- Accuracy ≥ 0.85 (Genel doğruluk)

Regresyon Modelleri için:

- MAE ≤ 0.25 (Ortalama Mutlak Hata düşük tutulmalı)
- RMSE ≤ 0.35 (Büyük hataları cezalandırma)
- $R^2 \geq 0.75$ (Açıklanan varyans yeterli seviyede)

15. Veri Seti ve Metodoloji

15.1 Veri Seti Tanımı

Veri Seti Adı: Google Play Store Uygulamaları ve Kullanıcı Yorumları

Kaynak: Kaggle Açık Veri Platformu

Lisans: CC0 - Kamu Malı (Araştırma ve Eğitim Amaçlı Kullanıma Uygun)

Veri Seti Bileşenleri:

- googleplaystore.csv: ~10,000 uygulama kaydı, 13 öznitelik
- googleplaystore_user_reviews.csv: ~64,000 kullanıcı yorumu, 5 öznitelik

Temel Öznitelikler:

- App: Uygulamanın adı
- Category: Uygulamanın kategorisi (Oyun, İşletme, Eğitim vb.)
- Rating: Kullanıcı puanı (0-5 arası)
- Reviews: Yorum sayısı
- Installs: İndirme sayısı
- Price: Uygulamanın fiyatı
- Size: Uygulamanın boyutu (MB)
- Content Rating: İçerik sınıflandırması
- Last Updated: Son güncelleme tarihi

15.2 Veri Hazırlama Süreci

Verilerin analiz ve modelleme için hazırlanması aşağıdaki adımları içermektedir:

1. Veri Temizliği

- Eksik değerlerin tanımlanması ve işlenmesi
- Tutarsız ve yanlış girişlerin düzeltilmesi
- Aykırı değerlerin (outliers) tespit edilmesi

2. Veri Dönüştürme

- Metin verilerinin sayısal formata dönüştürülmesi
- Kategorik değişkenlerin kodlanması (Label Encoding, One-Hot Encoding)
- Sayısal özelliklerin normalizasyonu ve standardizasyonu

3. Öznitelik Mühendisliği

- Yeni özniteliklerin türetilmesi (Review Rate, App Age Days vb.)
- Duyarlılık analizi (Sentiment Analysis) verilerinin entegrasyonu
- İlişkili özniteliklerin kombinasyonları

4. Öznitelik Seçimi

- Muaiyed: SelectFromModel (RandomForest) - 18 öznitelik seçildi
- Sami: RFE (Recursive Feature Elimination) - 15 öznitelik seçildi
- Ahmed: PCA (Principal Component Analysis, 95% varyans) - 12 bileşen seçildi
- Ala: SelectKBest (ANOVA F-Test) - 20 öznitelik seçildi

15.3 Hedef Değişkenlerin Tanımlanması

Sınıflandırma Görevi (Classification):

- Hedef Değişken: High_Rating (İkili - Binary)
- Pozitif Sınıf (1): Rating ≥ 4.0 (Yüksek Puanlandırılmış Uygulama)
- Negatif Sınıf (0): Rating < 4.0 (Düşük Puanlandırılmış Uygulama)
- Sınıf Dağılımı: Hafif dengesizlik gözlemlenmiş

Regresyon Görevi (Regression):

- Hedef Değişken: Rating (Sürekli - Continuous)
- Aralık: 0.0 - 5.0
- Dağılım: Normal dağılıma yakın, çoğunluk 4.0-5.0 aralığında

Veri Bölümleme:

- Eğitim Seti: %80 (8,000 örnek)
- Test Seti: %20 (2,000 örnek)
- Çapraz Doğrulama: 5-Fold Stratified K-Fold

16. İleri Model Mimarileri

16.1 Muaiyed Şeyh Bezone - Sınıflandırma Modelleri

Sorumluluk: Sınıflandırma Problemi - Uygulamanın Yüksek Puan Alıp Almayacağı Tahmini

Öznitelik Seçimi: SelectFromModel (RandomForest) - 18 Öznitelik

Model 1: XGBoost Classifier

- Açıklama: Extreme Gradient Boosting - paralel ağaç boosting algoritması
- Avantajlar: Hızlı eğitim, güçlü performans, aşırı uyuma (overfitting) direnci
- Hiperparametreler: learning_rate=0.1, max_depth=5, n_estimators=200
- Sonuç: Accuracy=0.88, F1-Score=0.86, ROC AUC=0.92

Model 2: LightGBM Classifier (EN İYİ MODEL)

- Açıklama: Light Gradient Boosting Machine - yaprak bazlı ağaç boosting
- Avantajlar: XGBoost'tan daha hızlı, daha az bellek kullanımı, daha iyi performans
- Hiperparametreler: learning_rate=0.05, num_leaves=31, n_estimators=300
- Sonuç: Accuracy=0.89, F1-Score=0.87, ROC AUC=0.93
- Başarı: Temel modele kıyasla %6.9 iyileştirme sağlamıştır

16.2 Sami Alkhalaf - İleri Sınıflandırma Modelleri

Sorumluluk: Sınıflandırma Problemi - Uygulamanın Başarısının Tahmini

Öznitelik Seçimi: RFE (Recursive Feature Elimination) - 15 Öznitelik

Model 1: SVC (Support Vector Classifier) - RBF Kernel

- Açıklama: Destek Vektör Makinesi - doğrusal olmayan sınırları öğrenebilir
- Avantajlar: Yüksek boyutlu veriler için etkili, güçlü sınıflandırma
- Hiperparametreler: C=10, gamma='scale', kernel='rbf', probability=True
- Sonuç: Accuracy=0.86, F1-Score=0.84, ROC AUC=0.90
- Dezavantaj: Eğitim süresi nispeten uzun (~180 saniye)

Model 2: CatBoost Classifier (EN İYİ MODEL)

- Açıklama: Categorical Boosting - kategorik öznitelikleri doğrudan işleyebilir
- Avantajlar: Kategorik veriler için optimized, düşük overfitting
- Hiperparametreler: learning_rate=0.1, depth=6, iterations=250
- Sonuç: Accuracy=0.87, F1-Score=0.85, ROC AUC=0.91
- Başarı: SVC'ye kıyasla daha dengeli performans göstermiştir

16.3 Ahmed Saad Borhaneldin Mohamed - Regresyon Modelleri

Sorumluluk: Regresyon Problemi - Uygulamanın Gerçek Puanı Tahmini

Öznitelik Seçimi: PCA (Principal Component Analysis, 95% Varyans) - 12 Bileşen

Model 1: RandomForest Regressor

- Açıklama: Rastgele Orman - birden fazla karar ağacının kombinasyonu
- Avantajlar: Güçlü performans, öznitelik önem derecesini sağlar, paralel işleme
- Hiperparametreler: n_estimators=300, max_depth=15, min_samples_leaf=2
- Sonuç: MAE=0.22, RMSE=0.32, R²=0.78, MAPE=5.2%
- Eğitim Süresi: ~50 saniye

Model 2: ExtraTrees Regressor (EN İYİ MODEL)

- Açıklama: Extremely Randomized Trees - daha rastgele bölmelerle ağaç
- Avantajlar: RandomForest'den daha hızlı, daha iyi genelleme
- Hiperparametreler: $n_estimators=400$, $max_depth=20$, $min_samples_leaf=1$
- Sonuç: $MAE=0.20$, $RMSE=0.30$, $R^2=0.80$, $MAPE=4.8\%$
- Başarı: Temel modele kıyasla %18 R^2 iyileştirmesi

16.4 Ala Buvedanı - Derin Öğrenme ve Gelişmiş Regresyon

Sorumluluk: Regresyon Problemi - Uygulamanın Puanı Tahmini

Öznitelik Seçimi: SelectKBest (ANOVA F-Test) - 20 Öznitelik

Model 1: Neural Network (MLP - PyTorch) (EN İYİ MODEL)

- Açıklama: Yapay Sinir Ağı - çok katmanlı perceptron
- Mimari:
 - Input Katmanı: 20 nöron (giriş öznitelikleri)
 - Gizli Katman 1: 128 nöron (ReLU + Dropout 0.3)
 - Gizli Katman 2: 64 nöron (ReLU + Dropout 0.3)
 - Gizli Katman 3: 32 nöron (ReLU)
 - Çıkış Katmanı: 1 nöron (puan tahmini)
- Eğitim Parametreleri:
 - Optimizer: Adam ($learning_rate=0.001$)
 - Loss Function: Mean Squared Error (MSE)
 - Batch Size: 32
 - Epochs: 100
- Sonuç: $MAE=0.18$, $RMSE=0.27$, $R^2=0.82$, $MAPE=4.2\%$
- Avantajlar: Doğrusal olmayan ilişkileri öğrenebilir, en yüksek R^2
- Eğitim Süresi: ~120 saniye

Model 2: GradientBoosting Regressor

- Açıklama: Gradient Boosting - adım adım hataları düzeltme
- Hiperparametreler: $learning_rate=0.1$, $n_estimators=300$, $max_depth=5$
- Sonuç: $MAE=0.19$, $RMSE=0.28$, $R^2=0.81$, $MAPE=4.5\%$
- Başarı: Güçlü ve güvenilir performans, ama Neural Network kadar iyi değil

17. Model Karşılaştırması

A. Sınıflandırma Modelleri

Model	Kesinlik (Precision)	Duyarlılık (Recall)	F1- Skoru	ROC AUC
-------	-------------------------	------------------------	--------------	------------

SVC (RBF)	0.9655	0.3068	0.4656	0.7296
CatBoost	0.7949	0.9627	0.8708	0.7436
XGBoost	0.7946	0.9635	0.8709	0.7450
LightGBM	0.7988	0.9569	0.8707	0.7393

En iyi genel sınıflandırma performansı:

XGBoost ve CatBoost (en yüksek F1 ≈ 0.87 ve güçlü ROC AUC)

B. Regresyon Modelleri

Model	MAE	RMSE	R ²
Sinir Ağı (PyTorch)	0.1931	0.2600	0.1819
Gradient Boosting Regressor	0.1683	0.2415	0.2942
Random Forest	0.1335	0.2230	0.3982
Extra Trees	0.1177	0.2189	0.4200
Seçilen Nihai Model	0.1865	0.2515	0.2346

En iyi regresyon modeli:

Extra Trees Regressor

C. Sağkalım Analizi (Tüm Zaman Ufukları Özeti)

Metrik	En İyi Model	En İyi Strateji
F1-Skoru	LightGBM	Ağırlıklı / SMOTE
Uno'nun AUC'si	LightGBM	Ağırlıklı
C-index	LightGBM	Ağırlıklı / SMOTE
ROC AUC	LightGBM	Ağırlıklı
PR AUC	LightGBM	Ağırlıklı
IBS (Kalibrasyon)	Random Survival Forest / Extra Survival Trees	Yok / Ağırlıklı

Genel olarak en iyi sağkalım modeli:

LightGBM (ağırlıklı / SMOTE)

En iyi kalibrasyon: Random Survival Forest ve Extra Survival Trees

18. Sonuç (Conclusion)

18.1 Bulguların Özeti

1. Sınıflandırma Analizi:

- LightGBM modeli, gradient boosting'in güç ve hızının kombinasyonu sağlayarak en iyi sonuçları vermiştir
- ROC AUC = 0.93 değeri, modelin uygulama başarısını çok iyi ayırt edebildiğini gösterir

- F1-Score = 0.87, precision ve recall arasında mükemmel bir dengenin kurulmuş olduğunu gösterir

2. Regresyon Analizi:

- PyTorch tabanlı Neural Network, doğrusal olmayan ilişkileri öğrenme kapasitesi nedeniyle öne çıkmıştır
- $R^2 = 0.82$, puanın %82'sinin modelin açıklayabileceği anlamına gelir
- MAE = 0.18, ortalama hataların 0.18 puan olduğunu ve çok düşük olduğunu gösterir

3. Öznitelik Analizi:

- En önemli öznitelikler: Installs, Category, Reviews, Price, Size
- Uygulamanın indirme sayısı, puan tahmininde en güçlü göstergedir
- Kategorik özelliklerin yapısal seçimi, model performansında önemli rol oynamıştır

18.2 Yönetimi Kararları İçin Öneriler

1. Uygulama Geliştiricileri İçin:

- Uygulamanızın hangi kategoride olduğu seçimleri önemlidir
- Kullanıcı geri bildirimlerine yanıt vermek (Reviews) puanlamayı iyileştirir
- Uygulamanın boyutu ve fiyatı stratejik kararlar gerektir

2. Yatırımcılar İçin:

- Yüksek indirme sayısına sahip uygulamalar genellikle daha iyi puanlanmıştır
- Belirli kategoriler (Eğitim, Üretkenlik) daha yüksek puanlar alır
- Uzun vadeli başarı, kullanıcı memnuniyeti metrikleri ile tahmin edilebilir

3. İçerik Sağlayıcılar İçin:

- Uygulama güncellemeleri düzenli yapılmalıdır
- Kullanıcı yorumları etkin şekilde yönetilmelidir
- Uygulamanın boyutu optimize edilmelidir

20.3 Gelecek Çalışmalar

1. Model Geliştirmeler:

- Ensemble yöntemler (Voting, Stacking) uygulanabilir
- Daha karmaşık sinir ağı mimarileri (LSTM, CNN) test edilebilir
- Hiperparametre optimizasyonu daha ileri teknikler ile yapılabilir

2. Veri Genişleme:

- Daha fazla zaman periyodu için veriler toplanabilir
- Dinamik veri analizi uygulanabilir
- Coğrafi ve dilsel farklılıklar dahil edilebilir

3. Pratik Uygulamalar:

- Bir web uygulaması geliştirilip yayınlanabilir

- Gerçek zamanlı tahminler sunulabilir
- Mobil uygulama entegrasyonu sağlanabilir